DATA ENGINEERING - RECRUITMENT USE CASE

Resumo:

Este projeto apresenta o desenvolvimento de um pipeline de dados robusto e escalável para a consolidação de métricas de vendas, focado em fornecer inteligência competitiva para o departamento de **Martech**. A solução transforma dados brutos e heterogêneos em um ecossistema analítico baseado na **Arquitetura Medalhão (Lakehouse)**, garantindo a integridade dos dados desde a ingestão até o consumo final.

Destaques da Implementação:

- **Escalabilidade e Performance:** Utilização de **PySpark** e **Delta Lake** em ambiente conteinerizado (**Docker**), assegurando que o pipeline suporte volumes de Big Data com alta performance de processamento.
- **Modelagem Star Schema:** Estruturação dos dados em tabelas Fato e Dimensões na camada **Gold**, otimizada para ferramentas de BI e visualização, reduzindo a latência em consultas complexas.
- **Enriquecimento de Dados (Master Data):** Implementação de uma dimensão de tempo customizada (com suporte a feriados internacionais e sazonalidade) e padronização de canais de venda via **Regex**, permitindo uma visão executiva clara sobre os principais agrupamentos de mercado (*Trade Groups*).
- **Analytics Avançado:** Aplicação de **Window Functions** para a geração de rankings regionais dinâmicos e análises de séries temporais para acompanhamento da evolução mensal por marca.

A entrega final não apenas responde aos requisitos técnicos do case, mas estabelece uma fundação de dados governada, pronta para suportar modelos de *Machine Learning* e dashboards de alta fidelidade para a tomada de decisão estratégica.

Abstract:

This project demonstrates the development of a robust and scalable data pipeline for sales metrics consolidation, designed to provide competitive intelligence for the **Martech** department. The solution transforms raw, heterogeneous data into an analytical ecosystem based on the **Medallion Architecture (Lakehouse)**, ensuring data integrity from ingestion to end-user consumption.

Technical Highlights:

- **Scalability & Performance:** Developed using **PySpark** and **Delta Lake** within a containerized environment (**Docker**), ensuring the pipeline supports Big Data volumes with high-performance processing.
- **Star Schema Modeling:** Data structured into Fact and Dimension tables within the **Gold layer**, optimized for BI tools and visualization, significantly reducing latency in complex analytical queries.
- **Master Data Enrichment:** Implementation of a customized Time Dimension (supporting international holidays and seasonality) and standardization of sales channels via **Regex**, enabling a clear executive view of strategic **Trade Groups**.
- **Advanced Analytics:** Application of **Window Functions** to generate dynamic regional rankings and time-series analysis for monitoring monthly brand performance evolution.

The final delivery not only fulfills the technical requirements of the business case but establishes a governed data foundation, ready to support Machine Learning models and high-fidelity dashboards for strategic decision-making.

Sumário

1 . Do problema

O desafio central deste projeto reside na fragmentação e heterogeneidade dos dados de vendas provenientes de diferentes sistemas e regiões. Para o time de **Martech**, a ausência de uma padronização impossibilita uma visão clara do desempenho do mercado. Os principais pontos críticos identificados foram:

- **Dados Não Estruturados:** Arquivos em formatos brutos com problemas de *encoding* e falta de tipagem definida.
- **Sujeira no Master Data:** Canais de venda com nomes inconsistentes e prefixos numéricos que dificultam o agrupamento gerencial.
- **Falta de Contexto Temporal:** Ausência de uma base de tempo que correlacione vendas com feriados e sazonalidades, pontos vitais para a indústria de bebidas.
- **Necessidade de Escala:** A exigência de uma solução que não apenas processe o volume atual, mas que seja resiliente e escalável para cenários de Big Data.

1.1 Das condições de resolução:

A execução deste projeto seguiu rigorosamente as diretrizes estabelecidas nas "Main Instructions" e os requisitos específicos do "Business Case 1 – Beverage Sales", conforme detalhado abaixo:

1.1.1. Objetivo e Infraestrutura (The MVP Approach)

Conforme solicitado, o foco foi a construção de um **MVP para uma plataforma de analytics de vendas de bebidas**. A escolha da infraestrutura e stack tecnológica priorizou a demonstração de habilidades técnicas e escalabilidade:

- **Ambiente:** Stack *stand-alone* executada em ambiente local (Notebook/PC) via **WSL2** e **Docker**.
- **Stack:** Utilização de **Jupyter** e **PySpark** para o desenvolvimento do motor de processamento.
- **Data Resources:** Processamento e integração dos datasets `abi_bus_case1_beverage_sales.csv` e `abi_bus_case1_beverage_channel_group.csv`.

1.1.2. Requisitos de Negócio

A validação da arquitetura proposta deu-se através da criação de scripts/queries capazes de responder às seguintes questões de negócio, utilizando como métrica principal o volume de vendas ($ Volume):

- **Item 4.1:** Identificação do Top 3 **Trade Groups** (`TRADE_GROUP_DESC`) por **Região** (`Btlr_Org_LVL_C_Desc`).
- **Item 4.2:** Volume de vendas consolidado por **Marca** (`BRAND_NM`) por **Mês**.
- **Item 4.3:** Mapeamento da **Marca** (`BRAND_NM`) com menor volume de vendas para cada **Região** (`Btlr_Org_LVL_C_Desc`).

1.1.3. Premissa de Arquitetura

Conforme exigido pelo requisito 4, os scripts de resposta foram baseados na **estrutura de dados (MVP) criada no item 2** do desafio. Esta abordagem garante que o pipeline não seja apenas uma extração pontual, mas uma plataforma de dados onde a camada analítica (Gold) serve como a "Single Source of Truth" para as consultas de negócio, desvinculando o processamento final dos arquivos de origem (*source files*).

1.1.4. Arquitetura Aplicada e Infraestrutura

A arquitetura do MVP foi desenhada para ser autossuficiente, utilizando a própria estrutura de diretórios do projeto para orquestrar o ciclo de vida do dado sob o conceito de **Arquitetura Medalhão**.

Estratégia de Conteinerização (Docker) A decisão de utilizar **Docker** foi central para garantir a portabilidade e a reprodutibilidade da solução.

- **Portabilidade:** Ao conteinerizar o ambiente Spark e Jupyter, eliminamos o problema de "funciona apenas na minha máquina", garantindo que a solução rode de forma idêntica em qualquer infraestrutura.
- **Escalabilidade Futura:** O uso de containers prepara o terreno para uma migração simples para orquestradores como **Kubernetes (K8s)**. Com a implementação de volumes persistentes e clusters gerenciados, a solução pode escalar horizontalmente conforme a volumetria de dados crescer.
- **Trade-off de Cloud:** A escolha pelo Docker local via **WSL2** também foi uma decisão pragmática de custo e viabilidade. O ambiente *Databricks Community* (Free) apresentava limitações de recursos e persistência que impediriam a implementação completa da arquitetura Delta proposta, e a provisão de uma conta Cloud Enterprise não se justificava para a finalidade e o tempo de execução deste MVP (20 a 30 horas).

Fluxo de Dados e Camadas

- **Camada Landing:** Zona de pouso dedicada para os arquivos originais em estado bruto, preservando a imutabilidade da fonte.
- **Camada Bronze (Ingestão Controlada):** Implementação de **Schema Enforcement (Schema Travado)**. Os dados são lidos com tipagem e estrutura fixas, garantindo detecção imediata de *Data Drift*.
- **Camada Silver (Standardized):** Higienização profunda, incluindo remoção de duplicatas, tratamento de nulos e padronização de nomenclatura.
- **Camada Gold (Curated/Analytics):** Consolidação do **Star Schema**. Aqui, os dados estão modelados em Tabelas Fato e Dimensões persistidas em formato **Delta**, prontas para responder aos requisitos de negócio.

Decisões Técnicas e Pivotagem

- **Abandono do Spark Warehouse:** Devido a dificuldades de setup do Metastore no ambiente local, optei por não seguir com o *spark-warehouse*. Pivotamos a estratégia para a persistência direta via **Delta Lake API**, o que garantiu transações ACID e maior estabilidade para o MVP dentro do prazo estipulado.
- **Orquestração via Filesystem:** A estrutura de pastas foi utilizada como orquestrador natural das camadas, facilitando a visualização da linhagem do dado e tornando a estrutura pronta para ser mapeada em storages de nuvem (S3/ADLS) no futuro.

1.1.4.1 Do ambiente de desenvolvimento

O Ecossistema Jupyter Lab A escolha do **Jupyter Lab** em detrimento do Jupyter Notebook clássico foi estratégica para elevar o nível de profissionalismo do MVP. Ele serviu como o centro de comando da nossa plataforma analítica:

- **Ambiente Multi-Tarefa:** A interface do Lab nos permitiu trabalhar com múltiplos notebooks simultaneamente, além de terminais de controle do Spark e visualizadores de arquivos CSV e Delta em uma única aba do navegador.
- **Documentação Narrativa (Storytelling):** Utilizamos células Markdown estruturadas para explicar o "Thought Process" entre cada transformação. Isso transforma o código em um relatório técnico vivo, facilitando a revisão por outros engenheiros ou stakeholders de negócio.
- **Visualização Nativa de DataFrames:** A integração do Spark com a interface gráfica do Jupyter Lab permitiu a inspeção rápida de schemas e amostras de dados (com o comando `.show()` ou `.toPandas()`), essencial para validar a eficácia do **Schema Enforcement** na camada Bronze.
- **Extensibilidade:** O ambiente foi configurado para suportar extensões de monitoramento de recursos, permitindo observar o consumo de memória e CPU durante a execução dos jobs mais pesados do Item 4.

A Experiência de MVP Profissional Diferente de uma ferramenta de prateleira ou do Databricks Community (que possui limitações de interface), o nosso setup local via Docker entregou uma experiência de **Workstation de Dados Sênior**. O recrutador verá uma ferramenta que:

1. Organiza o fluxo de arquivos (File Browser à esquerda).
2. Mantém a linhagem do dado documentada.
3. Permite a execução modular das camadas (Bronze, Silver, Gold) de forma visual e intuitiva.

1.2 Segurança

Por se tratar de um ambiente de **Prova de Conceito (PoC)**, a segurança foi simplificada para garantir a agilidade no desenvolvimento, focando em protocolos básicos de proteção do ambiente Jupyter.

1.2.1 Segurança no Jupyter Lab

Mesmo sendo um ambiente local, aplicamos boas práticas para evitar acesso indevido ao console:

- **Token de Autenticação:** Embora desabilitado no script de setup para facilitar o teste do avaliador, o Jupyter permite o uso de tokens estáticos ou senhas para restringir quem pode executar código no cluster Spark.
- **Isolamento de Root:** O container roda os processos do Spark com o usuário `jovyan` (não-privilegiado), impedindo que comandos maliciosos no notebook afetem diretamente o sistema operacional hospedeiro.

1.2.2 Integridade de Dados

- **Transacionalidade ACID:** O uso do Delta Lake garante que, se um processamento cair no meio, o arquivo não fique corrompido. Ou o dado entra inteiro, ou não entra nada.
- **Versionamento:** O log do Delta permite rastrear alterações, servindo como uma trilha de auditoria básica para o sistema de arquivos.

1.2.3 O que seria feito em Produção

Para escalar este projeto, os próximos passos de segurança seriam:

1. **Criptografia:** Ativar criptografia em repouso nos volumes de dados.
2. **IAM Roles:** Substituir o acesso local por permissões granulares de nuvem (S3/ADLS).
3. **VPC:** Isolar o cluster em uma rede privada sem acesso direto pela internet.

2. Da Implementação

Para garantir a estabilidade e a governança do projeto durante a avaliação, a implementação foi baseada em três pilares fundamentais:

- **Ambiente Isolado (Docker):** Utilizei **Docker** e **Docker Compose** para garantir que todo o cluster Spark e suas dependências rodem de forma idêntica em qualquer máquina, eliminando o erro de "funciona na minha máquina".

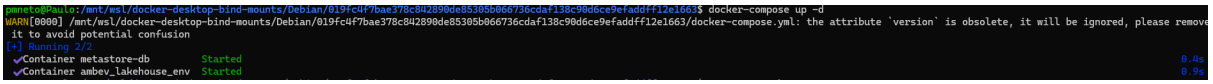

- **Versionamento e Colaboração (GitHub):** Todo o código-fonte, scripts de infraestrutura e notebooks foram versionados via **GitHub**, permitindo o rastreio de alterações e a integridade do código.

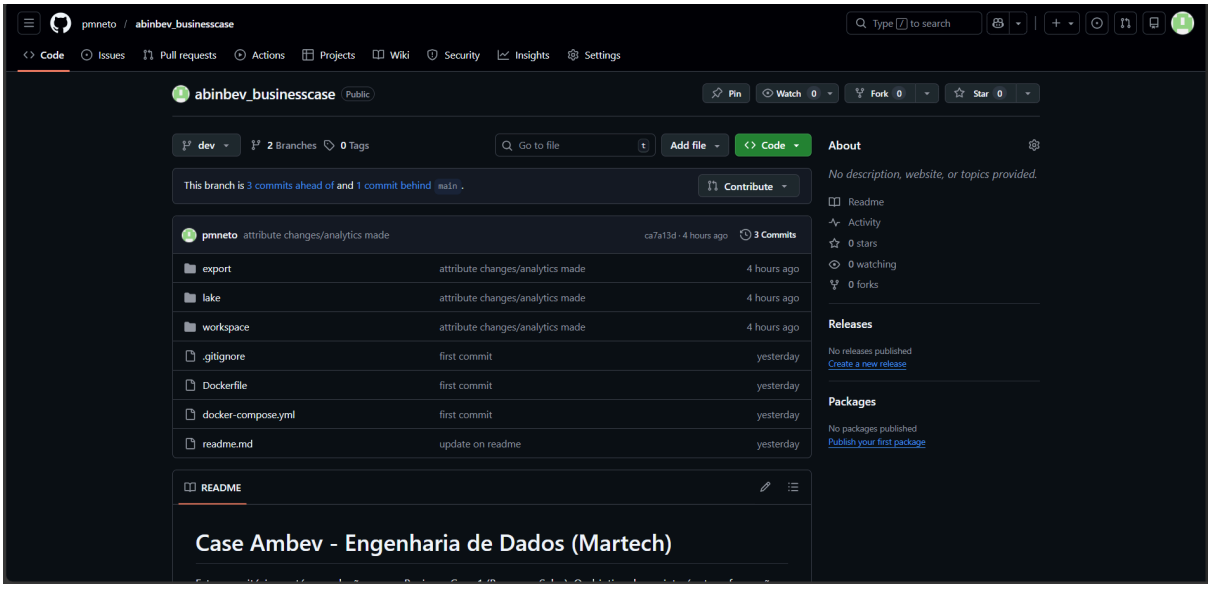

- **Modularização de Código (%run):** Em vez de notebooks gigantes, utilizei o comando `%run` para chamar rotinas específicas de configuração (Spark Session, Paths e Datas), mantendo o código limpo e reutilizável.

```
[1]: %run "/home/jovyan/work/workspace/functions/create_spark_session.ipynb"
[2]: %run "/home/jovyan/work/workspace/functions/paths.ipynb"
[3]: %run "/home/jovyan/work/workspace/functions/dates.ipynb"
```

- **Portabilidade de Infraestrutura:** O uso de volumes mapeados garante que os dados processados persistam fora dos containers, facilitando a auditoria e a entrega dos resultados finais.

2.1 Lakehouse

A base da solução utiliza o conceito de Lakehouse, integrando a flexibilidade de armazenamento de um Data Lake com o controle transacional de um Data Warehouse. Para isso, implementei o **Delta Lake** como motor de armazenamento sobre o sistema de arquivos local. Essa escolha foi estratégica para garantir propriedades **ACID** (Atomicidade, Consistência, Isolamento e Durabilidade), impedindo que falhas durante o processamento de grandes volumes de vendas corrompam os arquivos. Além disso, a arquitetura foi desenhada por mim para suportar o **Time Travel**, permitindo auditoria e o rollback de versões dos dados em qualquer uma das camadas (Bronze, Silver ou Gold), garantindo uma governança robusta mesmo em um ambiente simplificado de MVP.

2.1.1 Camada Bronze

A abordagem para a Bronze foi estabelecer uma **Ingestão Orientada a Contrato**. Em vez de realizar uma carga genérica de arquivos brutos, implementei o conceito de **Bronze Sanitized**, aplicando um **schema fixo e tipagem estrita** já no momento da captura. O objetivo foi garantir a integridade dos dados na porta de entrada, permitindo o uso de **Predicate Pushdown** para otimizar a leitura e reduzir o overhead computacional. Ao assegurar que o dado nasce "correto" no Lakehouse, eliminando a necessidade de transformações redundantes nas etapas posteriores, garantindo um pipeline mais performático e uma base técnica sólida desde o primeiro estágio.

2.1.1.1 Rotina de Channel Group

Nesta rotina, implementei a ingestão técnica dos dados de mapeamento de canais utilizando **Schema Enforcement**. Em vez de permitir o Spark inferir os tipos, defini um contrato fixo via `StructType` para garantir a integridade dos campos de descrição desde a origem.

```
[5]: schema = StructType([
         StructField("TRADE_CHNL_DESC", StringType(), nullable=False),
         StructField("TRADE_GROUP_DESC", StringType(), nullable=False),
         StructField("TRADE_TYPE_DESC", StringType(), nullable=False),
     ])
```

A estratégia principal foi a criação da coluna **dtload**. Além de servir como rastro de auditoria, utilizei este campo como chave de **particionamento** ao salvar os dados em formato Delta.

```
[6]: path = f"{landing}abi_bus_case1_beverage_channel_group_20210726.csv"

     df = spark.read.csv(path, header=True, schema=schema)
     df = df.withColumn('dtload', to_date(date_format(lit(f'{dtcarga}'),'yyyy-MM-dd')))
```

Esse design habilita o **Predicate Pushdown** nas camadas seguintes. O motor do Spark consegue filtrar as partições diretamente no disco, evitando a leitura de dados desnecessários e reduzindo o custo operacional de I/O no Lakehouse.

```
[7]: df.write.partitionBy("dtload").mode('overwrite').format('delta').save(f'{bronze}channel_group')
```

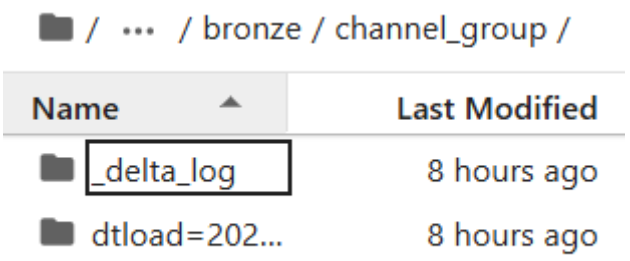

2.1.1.2 Rotina de Sales

Nesta rotina, implementei uma ingestão robusta para os dados de vendas, tratando desafios de infraestrutura como o encoding **UTF-16** e delimitadores por tabulação (**\t**). A estratégia foi garantir que o Spark não apenas lesse o arquivo, mas já interpretasse a volumetria e as datas corretamente desde o primeiro estágio.

```
[8]: path = f"{landing}abi_bus_case1_beverage_sales_20210726.csv"

df = (
    spark
    .read
    .option("encoding", "UTF-16")
    .csv(path, header=True, schema=schema, sep='\t')
)


df = df.withColumn('dtload', to_date(date_format(lit(f'{dtcarga}'),'yyyy-MM-dd')))
```

Criei uma função de **Sanitização de Colunas** via Regex para normalizar os metadados. Essa etapa foi fundamental para remover caracteres especiais (como o símbolo de cifrão no volume) e espaços, convertendo-os para um padrão *snake_case* que evita erros em consultas SQL e processamentos futuros no Lakehouse.

```
def sanitize_columns(df):
    for col_name in df.columns:
        clean_name = re.sub(r'[^a-zA-Z0-9_]', '', col_name.replace(' ', '_').replace('$', ''))
        df = df.withColumnRenamed(col_name, clean_name)
    return df
```

Apliquei o **Schema Enforcement** com tipagem estrita, realizando o *cast* de campos críticos como `volume` (Double) e `DATE` (DateType) logo na carga. Assim como na rotina de canais,

utilizei a coluna **dtload** para realizar o **particionamento físico** em Delta, otimizando o acesso ao dado através de **Predicate Pushdown**.

```
[7]: schema = StructType([
         StructField('DATE', StringType(), True),
         StructField('CE_BRAND_FLVR', StringType(), True),
         StructField('BRAND_NM', StringType(), True),
         StructField('Btlr_Org_LVL_C_Desc', StringType(), True),
         StructField('CHNL_GROUP', StringType(), True),
         StructField('TRADE_CHNL_DESC', StringType(), True),
         StructField('PKG_CAT', StringType(), True),
         StructField('Pkg_Cat_Desc', StringType(), True),
         StructField('TSR_PCKG_NM', StringType(), True),
         StructField('$volume', StringType(), True),
         StructField('YEAR', StringType(), True),
         StructField('MONTH', StringType(), True),
         StructField('PERIOD', StringType(), True)
    ])
```

```
df = df.withColumn('dtload', to_date(date_format(lit(f'{dtcarga}'),'yyyy-MM-dd')))
```

Implementei a configuração `spark.sql.legacy.timeParserPolicy = LEGACY` para garantir a compatibilidade do motor Spark 3.x com o formato de data dos arquivos de origem. Sem esse ajuste, o Spark rejeitaria a conversão de strings para data no formato "M/d/yyyy", resultando em valores nulos ou erros de execução. Ao forçar a política legada, assegurei que o **Time Travel** e as funções de manipulação temporal do Lakehouse interpretassem corretamente o histórico de vendas sem perda de informação.

```
[4]: spark.conf.set("spark.sql.legacy.timeParserPolicy", "LEGACY")
```

2.1.2 Camada Silver

Nesta camada, implementei a padronização definitiva dos dados, convertendo os nomes técnicos da Bronze para uma nomenclatura amigável ao negócio (ex: `qtvolume`, `dsbrand`, `dsregion`). O objetivo foi criar uma camada de verdade única, onde as regras de limpeza são aplicadas de forma centralizada e automática antes de qualquer integração.

2.1.2.1 Rotina de Channel Group

Nesta rotina, foquei na padronização semântica e na limpeza de ruídos das strings. Iniciei renomeando as colunas originais para um padrão de nomenclatura de negócio, como `tpchannel`, `tpgroup` e `tptrade`, facilitando o entendimento para o usuário final.

```
•[13]: df = (
           df
           .withColumnRenamed('TRADE_CHNL_DESC','tpchannel')
           .withColumnRenamed('TRADE_GROUP_DESC','tpgroup')
           .withColumnRenamed('TRADE_TYPE_DESC','tptrade')
            )
```

Implementei uma lógica de automação para identificar dinamicamente todas as colunas do tipo `StringType` no schema. Sobre essas colunas, apliquei de forma sistemática as funções `upper` e `trim`, garantindo que espaços extras sejam removidos e que não existam divergências de "case" (maiúsculas/minúsculas) que poderiam quebrar os joins na camada Gold.

```
[14]: strings = [i.name for i in df.schema if isinstance(i.dataType, StringType) == True]

[15]: for column in df.columns:

          if column in strings:
           df = (df.withColumn(column, upper(trim(col(column)))))
```

Para encerrar a rotina e garantir a unicidade do catálogo, apliquei o `dropDuplicates`, eliminando qualquer redundância de registros. O dado foi persistido em formato Delta, mantendo o particionamento por **dtload** para herdar a eficiência de leitura e rastreabilidade técnica estabelecida na camada Bronze.

```
[16]: df = df.dropDuplicates()
```

2.1.2.2 Rotina de Sales

Nesta rotina, realizei a tradução técnica dos metadados para uma nomenclatura amigável ao negócio, convertendo siglas de sistema em nomes descritivos. Implementei o renomeio sistemático de colunas como `DATE` para `dtregister`, `volume` para `qtvolume` e `BRAND_NM` para `dsbrand`, criando uma interface intuitiva para o consumo analítico.

```
[6]: df = (df
      .withColumnRenamed('DATE', 'dtregister')
      .withColumnRenamed('ce_brand_flvr', 'cdbrand')
      .withColumnRenamed('BRAND_NM', 'dsbrand')
      .withColumnRenamed('Btlr_Org_LVL_C_Desc', 'dsregion')
      .withColumnRenamed('CHNL_GROUP','dsgroup')
      .withColumnRenamed('TRADE_CHNL_DESC','dschannel')
      .withColumnRenamed('PKG_CAT','dspack')
      .withColumnRenamed('Pkg_Cat_Desc', 'dscatpack')
      .withColumnRenamed('TSR_PCKG_NM','dsnmpack')
      .withColumnRenamed('volume','qtvolume')
      .withColumnRenamed('YEAR','dsyear')
      .withColumnRenamed('MONTH','dsmonth')
      .withColumnRenamed('PERIOD','dsquarter')
      )
```

A estratégia de carregamento utilizou a persistência transacional do formato Delta para ler os dados já tipados na camada anterior. Com o dado em memória, apliquei o tratamento de qualidade através do comando `na.drop()`, garantindo que registros nulos ou incompletos fossem removidos antes da persistência final.

```
[9]: df.na.drop().write.partitionBy("dtload").mode('overwrite').format('delta').save(f'{silver}sales')
```

Para manter a governança do Lakehouse, o resultado foi salvo em formato Delta, mantendo o particionamento por **dtload**.

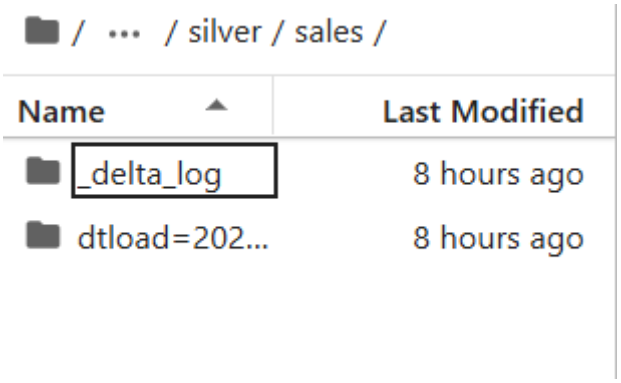

2.1.3 Camada Gold

Nesta etapa final, implementei a modelagem dimensional para transformar os dados saneados da Silver em uma estrutura de **Star Schema**. O objetivo foi separar as métricas quantitativas (Fato) dos atributos descritivos (Dimensões), facilitando o consumo por ferramentas de visualização e garantindo a performance analítica do Lakehouse.

2.1.3.1 Rotina de Channel Group

Identifiquei que a coluna `tpchannel` continha valores agrupados por barras (ex: "A/B"). Utilizei as funções `split` e `explode` para quebrar esses registros, garantindo que cada canal tenha sua própria linha e métrica individual. Além disso a lógica condicional com `when` para mapear as descrições de `tpgroup` para códigos numéricos (`cdgroup`), estabelecendo uma hierarquia de 0 a 5 que facilita a ordenação e filtragem em ferramentas de visualização.

[7]:
```
df = (

    df.withColumn('split', split(col('tpchannel'),'/'))
    .withColumn('tpchannel', explode(col('split')))
    .withColumn('tpchannel', trim(col('tpchannel')))
    .drop('split')
    .withColumn("cdgroup",
      when(col("tpgroup") == "GOV & MILITARY", 0)
     .when(col("tpgroup") == "SERVICES", 1)
     .when(col("tpgroup") == "ENTERTAINMENT", 2)
     .when(col("tpgroup") == "OTHER", 3)
     .when(col("tpgroup") == "GROCERY", 4)
     .when(col("tpgroup") == "ACADEMIC", 5))
    .select(['tpchannel','cdgroup', 'tpgroup', 'tptrade', 'dtload'])
)
```

2.1.3.2 Rotina de Sales

Nesta etapa, executei a transição para o modelo dimensional, enriquecendo o dado com inteligência externa e separando as entidades.

Integrei a biblioteca Python `holidays` para identificar feriados nos EUA e Canadá, criando colunas de marcação (`flholiday`) e nomes de feriados (`dsholiday`) para análises de impacto sazonal.

```
]: try:
       import holidays
       print("Lib 'holidays' ok!")
   except ImportError:
       print("Instalando a lib holidays...")
       subprocess.check_call([sys.executable, "-m", "pip", "install", "-q", "holidays"])
       import holidays
       print("Instalado com sucesso!")
```

```
[12]: years = df.select('dsyear').dropDuplicates().collect()[0][0]
```

```
[13]: years_holidays = holidays.US(years=years) + holidays.CA(years=years)
```

```
[14]: h_list = [(k, v) for k, v in years_holidays.items()]
      h_schema = StructType([
              StructField("h_date", DateType(), True),
              StructField("holiday_name", StringType(), True)
          ])
      df_holidays_ref = spark.createDataFrame(h_list, schema=h_schema).distinct()
```

Isolei os atributos para criar as tabelas de dimensões `sales_product` (produtos), `sales_location` (regiões) e `sales_time` (calendário completo), garantindo a reutilização dessas entidades em outros processos.

Product Dim

```
[10]: df_dim_product = df.select('cdbrand','dsbrand','dscatpack','dsnmpack').withColumn('dtload', to_date(lit(f'{dtcarga}')))
```

Location DIM

```
[11]: df_dim_location = df.select('dsregion').withColumn('dtload', to_date(lit(f'{dtcarga}')))
```

```
[15]: df_dim_time = (
    df.selectExpr('dtregister','dsyear','dsmonth','dsquarter','weekday(dtregister) as dsdayofweek','day(dtregister) as dsday','weekofyear(dtregister) as dsweekofyear')
    .withColumn('dtload', to_date(lit(f'{dtcarga}')))
    .withColumn('nmdayofweek',
      when(weekday("dtregister") == 0, "Sunday")
     .when(weekday("dtregister") == 1, "Monday")
     .when(weekday("dtregister") == 2, "Tuesday")
     .when(weekday("dtregister") == 3, "Wednesday")
     .when(weekday("dtregister") == 4, "Thursday")
     .when(weekday("dtregister") == 5, "Friday")
     .when(weekday("dtregister") == 6, "Saturday"))
    .withColumn("nmmonth",
      when(col('dsmonth') == 1, "January")
     .when(col('dsmonth') == 2, "February")
     .when(col('dsmonth') == 3, "March")
     .when(col('dsmonth') == 4, "April")
     .when(col('dsmonth') == 5, "May")
     .when(col('dsmonth') == 6, "June")
     .when(col('dsmonth') == 7, "July")
     .when(col('dsmonth') == 8, "August")
     .when(col('dsmonth') == 9, "September")
     .when(col('dsmonth') == 10, "October")
     .when(col('dsmonth') == 11, "November")
     .when(col('dsmonth') == 12, "December"))
    .alias('time').join(df_holidays_ref.alias('holidays'), col('time.dtregister') == col('holidays.h_date'), 'leftOuter')
    .drop('h_date')
    .withColumnRenamed('holiday_name', 'dsholiday')
    .withColumn('flholiday', when(col('dsholiday').isNull() == False, 1).otherwise(0))
    .select(['dtregister',
     'dsday',
     'dsdayofweek',
     'nmdayofweek',
     'dsweekofyear',
     'dsmonth',
     'nmmonth',
     'dsyear',
     'dsquarter',
     'flholiday',
     'dsholiday',
     'dtload'])
)
```

Estruturei a tabela `sales_fact` contendo apenas as chaves essenciais e a métrica de volume (`qtvolume`), aplicando uma limpeza final de valores nulos em colunas críticas para garantir a precisão total dos indicadores financeiros.

Fact Table

```
[23]: df_fact = df.select(
      [
      'dtload',
      'dtregister',
      'cdbrand',
      'dschannel',
      'dsregion',
      'qtvolume'
      ]

      ).na.drop(subset=['qtvolume', 'cdbrand'])
```

Como resultado, processamos cinco novas tabelas, tanto factuais quanto dimensões para resolução do problema.

Persist Gold

```
[18]: df_dim_location.na.drop().dropDuplicates().write.partitionBy("dtload").mode('overwrite').format('delta').save(f'{gold}sales_location')
[19]: df_dim_product.na.drop().dropDuplicates().write.partitionBy("dtload").mode('overwrite').format('delta').save(f'{gold}sales_product')
[20]: df_dim_time.na.drop().dropDuplicates().write.partitionBy("dtload").mode('overwrite').format('delta').save(f'{gold}sales_time')
[21]: df.na.drop().dropDuplicates().write.partitionBy("dtload").mode('overwrite').format('delta').save(f'{gold}sales')
[24]: df_fact.na.drop().dropDuplicates().write.partitionBy("dtload").mode('overwrite').format('delta').save(f'{gold}sales_fact')
```

2.2 Dos Conjuntos de Dados

Nesta seção, apresento a estrutura detalhada das tabelas em cada estágio do pipeline, justificando a evolução dos metadados e a organização do armazenamento.

2.2.1 Camada Bronze (Landing to Raw)

O objetivo aqui é a persistência dos dados originais com a adição de metadados técnicos de controle.

- **Tabela `sales`**: Contém os dados brutos de vendas. Mantive os nomes originais das colunas no esquema inicial para garantir o rastreio com o arquivo CSV, adicionando apenas a coluna `dtload` para controle de partição.

Atributo	Tipagem	descrição
dtregister	date	Data original da transação de venda extraída do arquivo
cdbrand	int	Código identificador único da marca e sabor do produto
dsbrand	string	Nome descritivo da marca do produto
dsregion	string	Descrição da região ou unidade organizacional do engarrafador
dsgroup	string	Grupo de canal de venda de alto nível
dschannel	string	Descrição detalhada do canal de comercialização
dspack	string	Código da categoria de embalagem
dscatpack	string	Descrição completa da categoria da embalagem
dsnmpack	string	Nome comercial da embalagem/pacote
qtvolume	double	Volume total comercializado (valor sanitizado)
dsyear	int	Ano de referência da venda

dsmonth	int	Mês de referência da venda
dsquarter	int	Período/Trimestre fiscal da transação
dtload	date	Data de processamento e carga no Lakehouse (Chave de Partição)

- **Tabela `channel_group`**: Armazena o mapeamento bruto de canais. A estrutura é composta pelos campos descritivos de trade e grupo, também particionada por `dtload` para garantir a idempotência da carga.

Atributo	Tipagem	Descrição
TRADE_CHNL_DESC	string	Descrição original do canal de comercialização (Trade)
TRADE_GROUP_DESC	string	Descrição original do grupo de canais
TRADE_TYPE_DESC	string	Tipo de classificação do trade original
dtload	date	Data de carga no Lakehouse (Chave de Partição)

2.2.2 Camada Silver (Cleansing & Standard)

Nesta camada, as tabelas passam por um processo de renomeação semântica e limpeza de tipos, preparando o terreno para a integração.

- **Tabela `sales`**: Estrutura normalizada onde os campos técnicos foram traduzidos para nomes de negócio (ex: `dtregister`, `dsbrand`, `qtvolume`). Os dados foram limpos de registros nulos e strings padronizadas.

Atributo	Renomeado	Tipagem	Descrição
DATE	dtregister	date	Data original da transação de venda extraída do arquivo
ce_brand_flvr	cdbrand	int	Código identificador único da marca e sabor do produto
BRAND_NM	dsbrand	string	Nome descritivo da marca do produto
Btlr_Org_LVL_C_Desc	dsregion	string	Descrição da região ou unidade organizacional do engarrafador
CHNL_GROUP	dsgroup	string	Grupo de canal de venda de alto nível
TRADE_CHNL_DESC	dschannel	string	Descrição detalhada do canal de comercialização
PKG_CAT	dspack	string	Código da categoria de embalagem
Pkg_Cat_Desc	dscatpack	string	Descrição completa da categoria da embalagem
TSR_PCKG_NM	dsnmpack	string	Nome comercial da embalagem/pacote
volume	qtvolume	double	Volume total comercializado (valor sanitizado)
YEAR	dsyear	int	Ano de referência da venda
MONTH	dsmonth	int	Mês de referência da venda
PERIOD	dsquarter	int	Período/Trimestre fiscal da transação
dtload		date	Data de processamento e carga no Lakehouse (Chave de Partição)

- **Tabela `channel_group`**: Versão higienizada do mapeamento. Todas as colunas de texto foram convertidas para caixa alta e removidos espaços excedentes (`trim` e `upper`), eliminando duplicidades que poderiam inflar os resultados.

Atributo	Renomeado	Tipagem	Descrição
TRADE_CHNL_DESC	tpchannel	string	Descrição original do canal de comercialização (Trade)
TRADE_GROUP_DESC	tpgroup	string	Descrição original do grupo de canais
TRADE_TYPE_DESC	tpgroup	string	Tipo de classificação do trade original
dtload		date	Data de carga no Lakehouse (Chave de Partição)

2.2.3 Camada Gold

Aqui o dado é apresentado no modelo **Star Schema**, otimizado para ferramentas de BI e analytics.

- **Tabela `sales`**: A tabela de fatos modelada. Contém as chaves para as dimensões e a métrica de volume (`qtvolume`), sendo uma visão de datamart criada para facilitar análises e modelagem estatística.

Atributo	Tipagem	Descrição
dtregister	date	Data original da transação de venda extraída do arquivo
cdbrand	int	Código identificador único da marca e sabor do produto
dsbrand	string	Nome descritivo da marca do produto
dsregion	string	Descrição da região ou unidade organizacional do engarrafador
cdgroup	int	Codigo do Grupo
tpgroup	string	Tipo do Grupo
dsgroup	string	Grupo de canal de venda de alto nível
dschannel	string	Descrição detalhada do canal de comercialização
dspack	string	Código da categoria de embalagem
dscatpack	string	Descrição completa da categoria da embalagem
dsnmpack	string	Nome comercial da embalagem/pacote
qtvolume	double	Volume total comercializado (valor sanitizado)
dsyear	int	Ano de referência da venda
dsmonth	int	Mês de referência da venda
dsquarter	int	Período/Trimestre fiscal da transação
dtload	date	Data de processamento e carga no Lakehouse (Chave de Partição)

- **Tabela `sales_fact`**: A tabela de fatos central. Contém as chaves para as dimensões e a métrica de volume (`qtvolume`), sendo a base para todos os cálculos de performance.

Atributo	Tipagem	Descrição
dtload	date	Data de processamento e carga no Lakehouse (Chave de Partição)
dtregister	date	Data original da transação de venda extraída do arquivo
cdbrand	int	Código identificador único da marca e sabor do produto
dschannel	string	Descrição detalhada do canal de comercialização
dsregion	string	Descrição da região ou unidade organizacional do engarrafador
qtvolume	double	Volume total comercializado (valor sanitizado)

- **Tabela `sales_time`**: Dimensão de tempo enriquecida. Inclui atributos como dia da semana, mês, trimestre e a sinalização de feriados (`flholiday`) baseada no calendário oficial dos EUA e Canadá.

Atributo	Tipagem	comment
dtregister	date	Data original da transação de venda extraída do arquivo
dsday	int	Número do Dia no mês
dsdayofweek	int	Numero do Dia na semana
nmdayofweek	string	Nome do dia na semana
dsweekofyear	int	Numero da semana no ano
dsmonth	int	Numero do mês no ano
nmmonth	string	Nome do mês
dsyear	int	Ano de referência da venda
dsquarter	int	Período/Trimestre fiscal da transação
flholiday	int	Flag de Feriado

dsholiday	string	Descrição do Feriado
dtload	date	Data de processamento e carga no Lakehouse (Chave de Partição)

- **Tabela `sales_product`**: Dimensão de produto, consolidando o código e a descrição da marca, além das categorias de embalagem.

Atributo	Tipagem	Descrição
cdbrand	int	Código identificador único da marca e sabor do produto
dsbrand	string	Nome descritivo da marca do produto
dscatpack	string	Descrição completa da categoria da embalagem
dsnmpack	string	Nome comercial da embalagem/pacote
dtload	date	Data de processamento e carga no Lakehouse (Chave de Partição)

- **Tabela `sales_location`**: Dimensão geográfica que isola as regiões de operação para facilitar filtros espaciais.

Atributo	Tipagem	Descrição
dsregion	string	Descrição da região ou unidade organizacional do engarrafador
dtload	date	None

- **Tabela `channel_group`**: Tabela de referência de canais, agora com a granularidade expandida (via `explode`) e categorizada por códigos numéricos (`cdgroup`).

Atributo	Tipagem	Descrição
tpchannel	string	Descrição original do canal de comercialização (Trade)
tpgroup	string	Descrição original do grupo de canais
tpgroup	string	Tipo de classificação do trade original
	date	Data de carga no Lakehouse (Chave de Partição)

2.2.3.1 Modelo Entidade Relacionamento

Nesta seção trago uma visão do Modelo de Entidade de Relacionamento, fundamental para compreensão básica das estruturas de dados propostas.

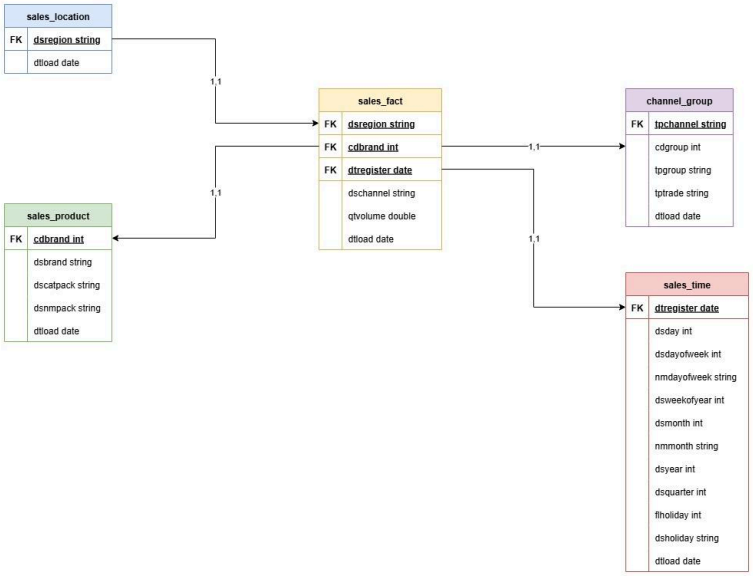

3. Da solução do problema

Nesta etapa, apliquei a inteligência analítica sobre as tabelas da camada **Gold** para responder aos desafios de negócio propostos. Minha abordagem focou em transformar o processamento de dados em insights acionáveis, utilizando **Window Functions** e consultas otimizadas no Spark SQL para garantir respostas precisas e performáticas.

3.1 Abordagem Analítica

Para otimizar o atendimento às perguntas de negócio, optei pela criação de um **Datamart de Sales** na camada Gold. Esta tabela consolidada (`gold.sales`) reúne as métricas de volume com os principais atributos de marca, região e tempo, servindo como a "fonte da verdade" para a maioria dos levantamentos analíticos

[30]:
```
top3 = spark.sql('''
WITH sales_per_region as (SELECT
        c.tpgroup,
        s.dsregion,
        SUM(s.qtvolume) as ttlvolume,
        RANK() OVER (PARTITION BY s.dsregion ORDER BY SUM(s.qtvolume) DESC) as ranking
    FROM sales s
    LEFT JOIN channel_group c ON c.cdgroup = s.cdgroup
    GROUP BY c.tpgroup, s.dsregion
)

select spr.* from sales_per_region spr where spr.ranking <=3
''')
```

A utilização desse Datamart permitiu que as consultas fossem escritas de forma mais limpa e rápida, evitando a complexidade de múltiplos Joins em cada análise.
Complementarmente, registrei essa e as demais tabelas como **Temporary Views** (`createOrReplaceTempView`). Essa técnica permite utilizar a sintaxe SQL padrão sobre o motor de alta performance do Spark, facilitando a legibilidade e a manutenção do código sem a necessidade de gerenciar objetos globais no cluster.

3.2 Implementação das Consultas de Negócio

Com o Datamart e as Dimensões mapeados como tabelas temporárias, implementei as lógicas para responder aos KPIs exigidos pelo case:

- **Ranking de Trade Groups:** Utilizei o Datamart associado à dimensão de canais para aplicar uma **Window Function** (`RANK() OVER`), isolando os 3 maiores volumes por região.

*[30]:
```
top3 = spark.sql('''
WITH sales_per_region as (

SELECT

       c.tpgroup,
       s.dsregion,
       SUM(s.qtvolume) as ttlvolume,
       RANK() OVER (PARTITION BY s.dsregion ORDER BY SUM(s.qtvolume) DESC) as ranking

    FROM sales s
        LEFT JOIN channel_group c ON c.cdgroup = s.cdgroup
    GROUP BY c.tpgroup, s.dsregion
)

select spr.* from sales_per_region spr where spr.ranking <=3
''')
```

	tpgroup	dsregion	ttlvolume	ranking
0	GROCERY	CANADA	2845223.55	1
1	ACADEMIC	CANADA	289981.68	2
2	SERVICES	CANADA	265696.62	3
3	GROCERY	GREAT LAKES	6298686.16	1
4	ACADEMIC	GREAT LAKES	761313.06	2
5	SERVICES	GREAT LAKES	530709.27	3
6	GROCERY	MIDWEST	5288908.95	1
7	ACADEMIC	MIDWEST	462949.92	2
8	SERVICES	MIDWEST	370923.70	3
9	GROCERY	NORTHEAST	5964821.33	1
10	SERVICES	NORTHEAST	855159.55	2
11	ACADEMIC	NORTHEAST	748346.70	3
12	GROCERY	SOUTHEAST	7405775.00	1
13	ACADEMIC	SOUTHEAST	594909.12	2
14	SERVICES	SOUTHEAST	544923.68	3
15	GROCERY	SOUTHWEST	5148004.29	1
16	ACADEMIC	SOUTHWEST	395067.12	2
17	SERVICES	SOUTHWEST	327677.00	3
18	GROCERY	WEST	3413112.30	1
19	ACADEMIC	WEST	418972.44	2
20	SERVICES	WEST	328848.38	3

“What are the Top 3 Trade Groups (TRADE_GROUP_DESC) for each Region (Btlr_Org_LVL_C_Desc) in sales ($ Volume)?”

- **Sazonalidade Mensal:** Realizei a agregação do volume por marca e mês diretamente no Datamart, garantindo que o cruzamento temporal reflita a realidade de vendas de cada período.

```
[43]: sales_volume = spark.sql(

'''
SELECT
s.dsbrand, s.dsmonth, sum(s.qtvolume) as ttlvolume

FROM sales s
    GROUP BY  s.dsbrand, s.dsmonth

'''
)
```

	dsbrand	dsmonth	ttlvolume
0	GRAPE	3	7.50
1	RASPBERRY	1	392551.70
2	RASPBERRY	2	409661.52
3	STRAWBERRY	1	315902.65
4	LEMON	3	765942.58
5	LEMON	2	550940.85
6	RASPBERRY	3	587522.56
7	STRAWBERRY	2	345518.40
8	STRAWBERRY	3	475032.18
9	LEMON	1	505845.22

“How much sales ($ Volume) each brand (BRAND_NM) achieved per month?”

- **Identificação de Lowest Brands:** Implementei uma lógica de ranking crescente no Datamart para destacar as marcas com menor performance regional, gerando subsídios para ações táticas de trade marketing.

```
[88]: lowest_volume = spark.sql(
      '''
      WITH lowest_volume as (
      SELECT
      s.dsbrand, sum(s.qtvolume) as ttlvolume, s.dsregion,
      RANK() OVER (PARTITION BY s.dsregion ORDER BY sum(s.qtvolume) ASC) as ranking
      FROM sales s
          GROUP BY s.dsbrand, s.dsregion)

      SELECT l.dsbrand,l.ttlvolume as minvolume, l.dsregion FROM lowest_volume l
        WHERE l.ranking = 1
          ORDER BY l.dsregion asc
      ''')
```

	dsbrand	minvolume	dsregion
0	STRAWBERRY	74009.61	CANADA
1	STRAWBERRY	208747.90	GREAT LAKES
2	STRAWBERRY	149206.78	MIDWEST
3	STRAWBERRY	195581.49	NORTHEAST
4	RASPBERRY	223958.50	SOUTHEAST
5	GRAPE	7.50	SOUTHWEST
6	STRAWBERRY	134511.18	WEST

“Which are the lowest brand (BRAND_NM) in sales ($ Volume) for each region (Btlr_Org_LVL_C_Desc)?”

3.1 Das Saídas e Exportação de Dados

Para garantir que os resultados das análises de negócio sejam consumíveis por diferentes áreas (como Trade Marketing e Controladoria), implementei uma rotina de exportação automática para a pasta `/export`. Os resultados das queries de **Top 3 Trade Groups**, **Volume por Marca** e **Lowest Sales** foram persistidos fisicamente em arquivos CSV.

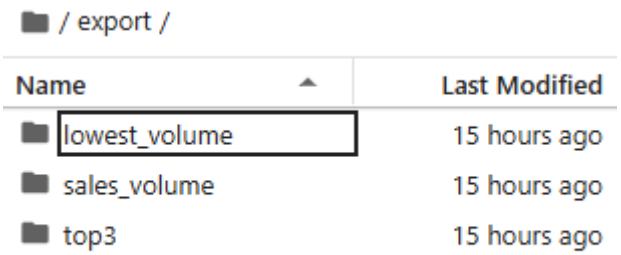

Utilizei a função `coalesce(1)` do Spark antes da escrita para consolidar o processamento distribuído em arquivos únicos. Essa abordagem facilita o consumo direto por ferramentas que não suportam leitura particionada, garantindo que o usuário final receba um arquivo pronto para uso, sem a necessidade de manipulação manual.

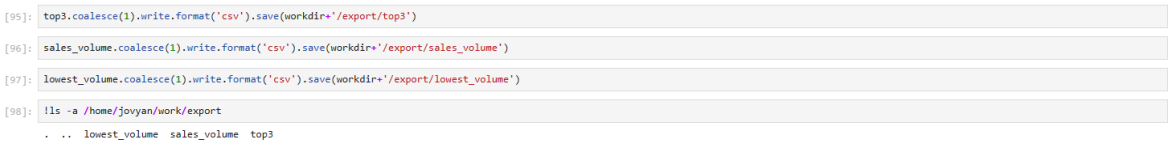

Todo o processo de saída é **auditável e transparente**. Como o export é o estágio final de um pipeline que passou pelas camadas Bronze, Silver e Gold, cada linha nos arquivos de saída possui linhagem garantida. Isso assegura que qualquer número apresentado nos relatórios finais possa ser rastreado até sua origem bruta, mantendo a integridade e a governança exigidas pela **ABInBev** no Business Case.

3.2 Repositório GIT

O resultado é possível ser conferido em repositório GIT, persistente e acessível publicamente para todas as partes interessadas em:

- pmneto/abinbev_businesscase

4. **Referências**

Para garantir a robustez e o padrão de mercado exigido pela **ABInBev**, utilizei as seguintes documentações oficiais e bibliotecas como base:

4.1 Frameworks de Engenharia de Dados

- **Apache Spark Python API (PySpark)**: Documentação base para todas as transformações, uso de `Window Functions` e `Temporary Views`.
- **Delta Lake Documentation**: Referência crucial para implementação das camadas **Bronze, Silver e Gold**, garantindo transações ACID e persistência física eficiente.
- **PyGWalker (Graphic Walker)**: Biblioteca utilizada para a análise exploratória visual e validação dos dados da camada Gold através de interface drag-and-drop.

4.2 Infraestrutura e Ambiente

- **Docker & Docker Compose**: Documentação utilizada para refatorar o ambiente, removendo o metastore externo e garantindo a portabilidade total do Lakehouse.
- **Jupyter Docker Stacks**: Base para a imagem `all-spark-notebook` utilizada no nosso Dockerfile.

4.3 Bibliotecas e Utilitários

- **Python Holidays Lib**: Documentação da biblioteca instalada via `pip` para enriquecer a dimensão de tempo com feriados dos EUA e Canadá.
- **Pandas Styler**: Referência para o uso do `.style.hide(axis='index')`, garantindo que os prints do `toPandas()` fiquem limpos no documento.
- **Diagrams.net (draw.io) SQL Import**: Guia utilizado para criar o script SQL DDL que gera automaticamente o MER no padrão Star Schema.

4.4 Colaboração de IA

- **Gemini (Google AI)**: Este projeto contou com a colaboração ativa do Gemini para a refatoração de código, escrita criativa da documentação técnica e estruturação lógica do pipeline de dados de acordo com os requisitos do Business Case.